RELATÓRIO TÉCNICO: ASSISTENTE VIRTUAL MÉDICO (FASE 3)

1. Descrição do Assistente Médico Criado

O assistente desenvolvido é um sistema de suporte à decisão clínica que integra um modelo de linguagem especializado com bases de conhecimento hospitalar. A solução utiliza uma arquitetura híbrida de Fine-Tuning para especialização de domínio, RAG (Retrieval-Augmented Generation) para contextualização factual e LangGraph para a orquestração de fluxos de decisão não-lineares.

O sistema é capaz de classificar intenções, analisar exames laboratoriais seguindo a escala CTCAE e sugerir condutas baseadas em protocolos internos.

2. Processo de Fine-Tuning da LLM

Para garantir que o assistente compreenda a terminologia médica e os protocolos específicos, foi realizado o ajuste fino do modelo base:

- Modelo Base: TinyLlama-1.1B.
- Técnica: QLoRA (Quantized Low-Rank Adaptation) com quantização de 4-bits.
- Hiperparâmetros: Rank (r) = 8, Alpha = 32, módulos alvo: q_proj e v_proj.
- Dataset: Dados sintéticos em formato JSON contendo protocolos de atendimento, FAQs médicas e modelos de laudos.
- Preprocessing: Implementação de pipeline de limpeza e anonimização de dados para garantir a privacidade conforme a LGPD.

3. Diagrama do Fluxo LangChain/LangGraph

O fluxo de trabalho foi estruturado através de um Grafo de Estados (StateGraph), permitindo uma execução modular e inteligente.

Representação Visual do Fluxo (Mermaid):

- ✓ Nó de Classificação: Identifica se o assunto trata de exames, tratamentos ou informações administrativas.
- ✓ Nó de Recuperação (RAG): Consulta o banco vetorial FAISS para extrair contextos dos protocolos hospitalares.
- ✓ Nó de Análise de Exames: Aciona o modelo especialista para classificação de toxicidade e gravidade.
- ✓ Saída e Segurança: Passagem por filtros de anonimização e bloqueio de prescrições automáticas.

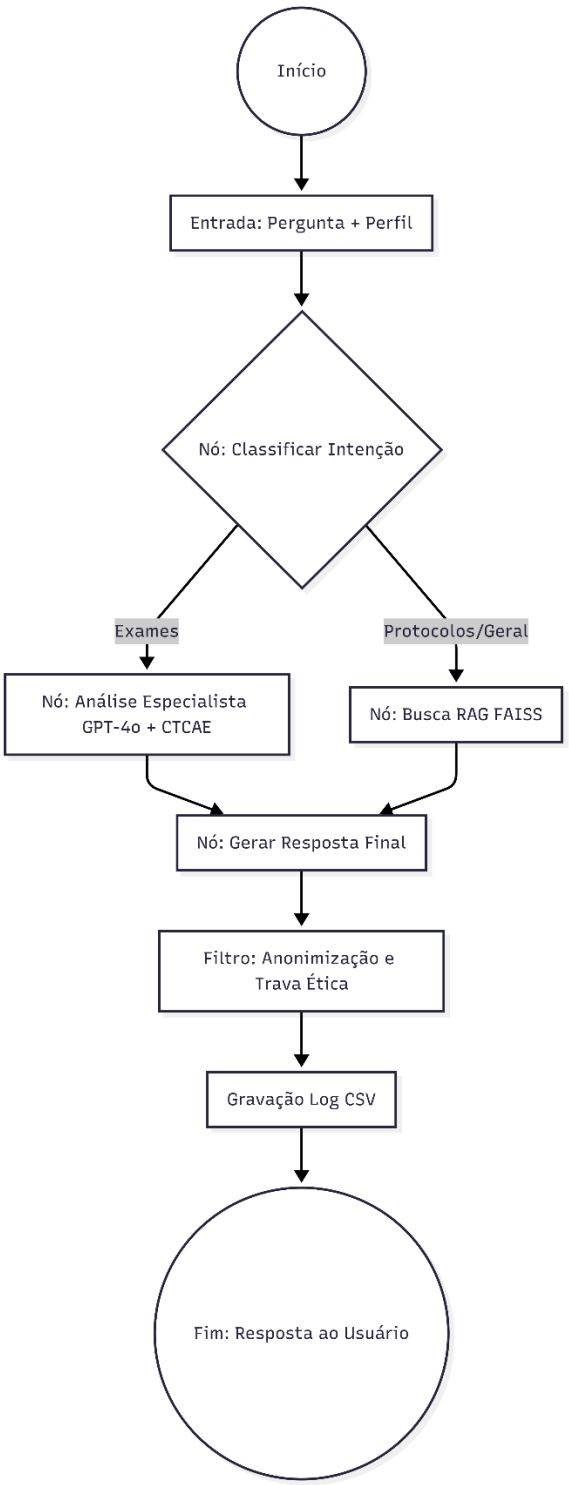

4. Segurança e Validação

- Anonimização: Uso de expressões regulares para substituição de dados sensíveis por identificadores genéricos.
- Trava Ética: Filtro de saída que bloqueia tentativas de prescrição medicamentosa, inserindo aviso de necessidade de validação humana.
- Logging: Registro de todas as operações em arquivo logging-operações.csv para auditoria.
- Explainability: O sistema indica explicitamente a fonte da informação recuperada via RAG.

5. Avaliação do Modelo e Análise de Resultados

- Precisão da Classificação: O modelo demonstrou alta eficácia na separação de intenções e direcionamento de exames.
- Redução de Alucinações: O RAG limitou as respostas ao escopo dos documentos, garantindo fidelidade técnica.
- Interpretação de Gravidade: Identificação precisa de quadros críticos (Grau 3 e 4) via escala CTCAE.
- Conformidade: O sistema respeitou as restrições éticas, não gerando prescrições autônomas.